

DL26: Deep Learning Advanced Models and Methods

Multi-source Domain Adaptation per il Riconoscimento di Azioni

Track 9 – Team DataLost

[repository](#) [GitHub](#)

MACCARRONE ALESSIA

JHOANNIS CACCAMO

MATTEO VULLO

Indice

Hook 01

Dati

Domain adaptation

Architettura MSDA 02

Gradient Reversal Layer (GRL)

Ensemble dinamico

Esperimenti 03

Analisi

Conclusioni

01

Hook MSDA: *la sfida del Domain Shift senza annotazioni*

I modelli video falliscono
quando cambia l'ambiente
(**Domain Shift**)

Etichettare video su un
nuovo dataset è **costoso**

fondere la conoscenza dei domini etichettati per
classificazioni delle azioni su un **terzo dominio non
etichettato**



Trasferimento della conoscenza

Sorgenti Labeled

HMDB-51
(1684 clip)

UCF-101
(1457 clip)

Target

Kinetics-400
(303 clip, piccolo e
unlabeled)




forte **sbilanciamento**
statistico (predominanza
classe **walk**)

Intersezione 11 classi




Bilanciamento delle classi

classe walk in HMDB



Riconoscimento di azioni umane

climb golf



kick_ball



pullup



punch



pushup



ride_bike



ride_horse



shoot_ball



shoot_bow



walk

UDA Closed Set



alcune **esclusioni** come 'fencing' (UCF-HMDB)

ed alcuni **accoppiamenti** come

'shoot_ball' -> 'Basketball' UCF, 'shooting basketball' Kinetics

...

canonical	HMDB-51	UCF-101	Kinetics-400
climb	climb	RopeClimbing	climbing a rope
golf	golf	GolfSwing	golf driving
kick_ball	kick_ball	SoccerPenalty	kicking soccer ball
pullup	pullup	PullUps	pull ups
punch	punch	Punch	punching person (boxing)
pushup	pushup	PushUps	push up
ride_bike	ride_bike	Biking	riding a bike
ride_horse	ride_horse	HorseRiding	riding or walking with horse
shoot_ball	shoot_ball	Basketball	shooting basketball
shoot_bow	shoot_bow	Archery	archery
walk	walk	WalkingWithDog	walking the dog

Modello Backbone

Information Leakage

R3D-18

pre-addestrato su Kinetics

Encode
condiviso

Classificatori
specifici


Ensemble pesato
dinamicamente

ResNet-50 ImageNet Inflated (I3D)

mai visto il target

Discriminatore
di dominio GRL


Domain Shift & Data Leak — Effetto del DA sull'Accuracy Target



Il MSDA Supera la Baseline e Risolve il Bias

02

Architetture




BASELINE


Feature extractor

label predictors

Input Batch Unificato
S1 (HMDB) + S2 (UCF) + Tgt (Kinetics)




Architetture: Baseline



- Nessun meccanismo di **adattamento** o **allineamento** delle distribuzioni.
- Il modello **non vede mai il dominio target**
- **Lower Bound**

MS-DANN

- Input Batch Unificato
- Doppio Obiettivo di Ottimizzazione
 - Minimizzazione della Loss di Classificazione
 - Massimizzazione della Loss di Dominio
- Gradient Reversal Layer (GRL)



Il Gradient Reversal Layer forza l'estrazione di feature universali (Domain-Invariant)


- Il Discriminatore a 3 vie cerca di indovinare da quale dataset proviene la clip.
- Il GRL inverte il gradiente (moltiplica $-\lambda$) durante la backpropagation.

Loss di classificazione

$$\mathcal{L}_{\text{tot}} = \mathcal{L}_{\text{cls}}^{S_1} + \mathcal{L}_{\text{cls}}^{S_2} + \lambda_{\text{adv}} \cdot \mathcal{L}_{\text{adv}}^{\text{TGT}}$$

Forza l'encoder a "dimenticare" i background specifici ed estrarre feature universali.

PCA 2D — Feature Reali dell'Encoder (Modello Addestrato)



- Ogni puntino rappresenta una clip video e i colori la provenienza (dominio)
- La PCA mostra come i 3 colori sono completamente mescolati e sovrapposti dimostrando che l'encoder ha imparato ad estrarre feature Domain-Invariant grazie al GRL.

**L'allineamento
avversariale unifica le
distribuzioni dei tre domini**

Pesatura con similarità del coseno


Collassa

Ensemble dinamico

più sei insicuro (alta entropia), meno il tuo voto conta (peso basso)

Pesatura per confidenza


La sorgente più sicura rispetto all'entropia delle predizioni riceve peso maggiore per quel batch target.



Ensemble dinamico

- Calcolo in training dei centroidi delle feature sorgente tramite Media Mobile Esponenziale (EMA).
- A tempo di inferenza, il peso (w_1, w_2) assegnato a ciascuna sorgente è proporzionale alla similarità coseno tra la clip target e i centroidi.


Pesatura
per
confidenza



Il modello resiste alla perdita casuale delle sorgenti





DataLost



Validazione Quantitativa: Impatto dei Domini e Contributo dei Moduli


Scaling Study




Ablation Analysis

- Top-1 Accuracy: **75.91%**
- Macro Precision: **75.02%**
- Macro Recall: **77.02%**
- Macro F1-Score: **74.25%**

La confusion matrix mostra una **diagonale più netta nel modello con ensemble dinamico** (*climb, pushup, ride bike*) mentre restano critiche delle **azioni più ambigue ma in minor misura**.



Misclassificazioni



Sviluppi futuri



Fine-Tuning End-to-End:

Portare il gradiente avversariale dentro i layer convoluzionali per allineare i dati spaziotemporali nativi.

Nuovi Backbone Video:

Utilizzare reti nate per il movimento puro (es. Something-Something) per guadagnare robustezza temporale senza ricadere nel Data Leak.

Calibrazione Automatica:

Introdurre Temperature Scaling avanzato per arginare matematicamente l'overconfidence.

Source Drop Semantico:

Passare da uno spegnimento "casuale" delle sorgenti a uno scarto intelligente dei batch che causano negative transfer.

M



GRAZIE!

